단국대학교 SW중심대학

전공별 AI활용

데이터 사전처리

CONTENTS

- **데이터프레임에는 원소 데이터 값이 종종 누락되는 경우가 있음**
  - 데이터를 파일로 입력할 때 빠뜨리거나 파일 형식을 변환하는 과정에서 데이터가 소실되는 것이 주요 원인
- **유효한 데이터 값이 존재하지 않은 누락 데이터를 NaN(Not a Number)로 표시**
- **머신러닝 분석 모형에 데이터를 입력하기 전에 반드시 누락 데이터를 제거하거나 다른 적절한 값으로 대체하는 과정이 필요**
  - 누락 데이터가 많아지면 데이터의 품질이 떨어지고, 머신러닝 분석 알고리즘을 왜곡하는 현상이 발생하기 때문

▪ 누락 데이터 확인

[예제 5-1] 누락 데이터 확인

Seaborn 라이브러리의 'titanic' 데이터셋을 사용한다. 첫 5행을 출력하면 'deck' 열에 NaN값이 있다. 이 승객의 경우 몇 번 데크에 승선했는지 데이터가 없다는 뜻이다.

```
2
3  # 라이브러리 불러오기
4  import seaborn as sns
5
6  # titanic 데이터셋 가져오기
7  df = sns.load_dataset('titanic')
```

〈IPython 실행〉 코드 1~7라인을 부분 실행한 후 IPython 콘솔에서 head() 메소드 실행

```
In [2]: df.head()
Out[2]:
   survived  pclass     sex   age  ...     deck  embark_town  alive  alone
0         0       3    male  22.0  ...      NaN  Southampton     no  False
1         1       1  female  38.0  ...        C    Cherbourg    yes  False
2         1       3  female  26.0  ...      NaN  Southampton    yes   True
3         1       1  female  35.0  ...        C  Southampton    yes  False
4         0       3    male  35.0  ...      NaN  Southampton     no   True

[5 rows x 15 columns]
```

▪ 누락 데이터 확인

[예제 5-1] 누락 데이터 확인

Info( ) 메소드로 데이터프레임의 요약 정보를 출력하면 각 열의 속하는 데이터 중에서 유효한 (non-null, 즉 NaN 값이 아닌) 값의 개수를 보여준다. RangeIndex를 보면 각 열의 891개의 데이터가 있다. 'deck' 열에는 203개의 유효한 범주형 데이터가 있다. (688개의 누락 데이터가 있음)

〈IPython 실행〉 IPython 콘솔에서 info() 메소드 실행

```
In [3]: df.info()
Out[3]:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 15 columns):
survived       891 non-null int64
pclass         891 non-null int64
sex            891 non-null object
age            714 non-null float64
sibsp          891 non-null int64
parch          891 non-null int64
fare           891 non-null float64
embarked       889 non-null object
class          891 non-null category
who            891 non-null object
adult_male     891 non-null bool
deck           203 non-null category
embark_town    889 non-null object
alive          891 non-null object
alone          891 non-null bool
dtypes: bool(2), category(2), float64(2), int64(4), object(5)
memory usage: 63.0+ KB
```

▪ 누락 데이터 확인

[예제 5-1] 누락 데이터 확인

value_count( ) 메소드를 이용하여 'deck'열에 688개의 누락 데이터가 있는 것을 파악할 수 있다.
단, 이때 **누락 데이터의 개수를 확인하려면 반드시 dropna = False 옵션을** 사용한다.
그렇지 않으면 NaN값을 제외하고 유효한 데이터의 개수만큼 구하기 때문이다.

```
 9  # deck 열의 NaN 개수 계산하기
10  nan_deck = df['deck'].value_counts(dropna=False)
11  print(nan_deck)
```

〈실행 결과〉 코드 9~11라인을 부분 실행

```
NaN    688
C       59
B       47
D       33
E       32
A       15
F       13
G        4
Name: deck, dtype: int64
```

▪ 누락 데이터 확인

[예제 5-1] 누락 데이터 확인

Notnull( ) 메소드를 적용하면 유효한 값이 있는 경우 True를 반환하고 누락 데이터가 있는 경우 False를 반환한다. 'deck' 열의 0행에 위치한 원소는 False 값을 갖기 때문에 누락 데이터이다.

```
16  # notnull() 메소드로 누락 데이터 찾기
17  print(df.head().notnull())
```

〈실행 결과〉 코드 16~17라인을 부분 실행

```
    survived  pclass   sex   age  ...   deck  embark_town  alive  alone
0       True    True  True  True  ...  False         True   True   True
1       True    True  True  True  ...   True         True   True   True
2       True    True  True  True  ...  False         True   True   True
3       True    True  True  True  ...   True         True   True   True
4       True    True  True  True  ...  False         True   True   True

[5 rows x 15 columns]
```

▪ 누락 데이터 확인

– **누락 데이터를 찾는 직접적인 방법으로 isnull( ) 메소드와 notnull( ) 메소드가 있음**

- **isnull()** : 누락 데이터면 True를 반환하고, 유효한 데이터가 존재하면 False를 반환한다.
- **notnull()** : 유효한 데이터가 존재하면 True를 반환하고, 누락 데이터면 False를 반환한다.

[예제 5-1] 누락 데이터 확인

head( ) 메소드를 적용하여 데이터프레임 객체를 반환하고 첫 5행의 원소들이 누락 데이터인지 여부를 isnull( ) 메소드를 적용하여 판별한다. 'deck' 열의 0행에 있는 원소는 True 값이므로 누락 데이터이다.

```
13  # isnull() 메소드로 누락 데이터 찾기
14  print(df.head().isnull())
```

〈실행 결과〉 코드 13~14라인을 부분 실행

	survived	pclass	sex	age	...	deck	embark_town	alive	alone
0	False	False	False	False	...	True	False	False	False
1	False	False	False	False	...	False	False	False	False
2	False	False	False	False	...	True	False	False	False
3	False	False	False	False	...	False	False	False	False
4	False	False	False	False	...	True	False	False	False

[5 rows x 15 columns]

〈실행 결과〉 코드 13~14라인을 부분 실행

	survived	pclass	sex	age	...	deck
0	False	False	False	False	...	True
1	False	False	False	False	...	False
2	False	False	False	False	...	True
3	False	False	False	False	...	False
4	False	False	False	False	...	True

[5 rows x 15 columns]

▪ 누락 데이터 확인

[예제 5-1] 누락 데이터 개수 계산

누락 데이터의 개수를 구할 때 isnull( ) 메소드와 notnull( ) 메소드를 활용할 수 있다.
isnull( ) 메소드의 경우 반환되는 값이 참이면 1, 거짓이면 0으로 판별한다.
Isnull( ) 메소드를 실행하고 **sum(axis=0) 메소드를 적용하면 참(1)의 합을 구한다**.
=> 각 열의 누락 데이터(NaN) 개수를 구할 수 있다. 'deck ' 열에만 3개의 누락 데이터가 존재한다.

```
19  # isnull() 메소드로 누락 데이터 개수 구하기
20  print(df.head().isnull().sum(axis=0))
```

〈실행 결과〉 코드 19~20라인을 부분 실행

```
survived       0
pclass         0
sex            0
age            0
sibsp          0
parch          0
fare           0
embarked       0
class          0
who            0
adult_male     0
deck           3
embark_town    0
alive          0
alone          0
dtype: int64
```

▪ 누락 데이터 제거

– 열을 삭제하면 분석 대상이 갖는 특성(변수)를 제거하고, 행을 삭제하면 분석 대상의 관측값(레코드)을 제거하게 됨

[예제 5-2] 누락 데이터 확인

'titanic' 데이터셋의 각 열(변수)에 누락 데이터가 몇 개씩 포함되어 있는지 체크한다.
Isnull( ) 메소드와 value_counts( ) 메소드를 적용한 결과, 'age' 열에 177개, 'embarked' 열에 2개, 'deck ' 열에 688개, 'embark_town ' 열에 2개가 있다.

```
# 라이브러리 불러오기
import seaborn as sns

# titanic 데이터셋 가져오기
df = sns.load_dataset('titanic')

# for 반복문으로 각 열의 NaN 개수 계산하기
missing_df = df.isnull()
for col in missing_df.columns:
  missing_count = missing_df[col].value_counts(dropna = False) #각 열의 고유값별 갯수 파악
  try:
    print(col, ': ', missing_count[True])   # NaN 값이 있으면 개수를 출력
  except:
    print(col, ': ', 0)                     # NaN 값이 없으면 0개 출력
```

```
False    889
True       2
Name: embarked, dtype: int64
```

〈실행 결과〉 코드 1~17라인을 부분 실행

```
survived : 0
pclass : 0
sex : 0
age : 177
sibsp : 0
parch : 0
fare : 0
embarked : 2
class : 0
who : 0
adult_male : 0
deck : 688
embark_town : 2
alive : 0
alone : 0
```

▪ 누락 데이터 제거

[예제 5-2] 누락 데이터 제거

전체 891명의 승객 중에서 688명의 데크(' deck ' 열) 데이터가 누락되어 있으며 차지하는 비율이 매우 높기 때문에 'deck'열의 누락 데이터를 삭제하여 분석에서 제외하도록 한다.
dropna( ) 메소드에 thresh=500 옵션을 적용하여 NaN값을 500개 이상 갖는 모든 열을 삭제한다.
=> 'deck' 열만 이 조건에 해당되어 제거된다.

```
19  # NaN값이 500개 이상인 열을 모두 삭제 - deck 열(891개 중 688개의 NaN값)
20  df_thresh = df.dropna(axis=1, thresh=500)
21  print(df_thresh.columns)
```

〈실행 결과〉 코드 19~21라인을 부분 실행

```
Index(['survived', 'pclass', 'sex', 'age', 'sibsp', 'parch', 'fare',
       'embarked', 'class', 'who', 'adult_male', 'embark_town', 'alive',
       'alone'],
      dtype='object')
```

▪ 누락 데이터 제거

[예제 5-2] 누락 데이터 제거

전체 891명의 승객 중에서 177명은 나이(age)에 대한 데이터가 없다.
승객의 나이가 데이터 분석의 중요한 변수라면 나이 데이터가 없는 승객의 레코드(행)을 제거하는 것이 좋다. dropna( ) 메소드에 기준이 되는 subset을 'age'열로 한정하면 'age' 열의 데이터 중에서 NaN값이 있는 행(axis=0)을 삭제한다. 기본값으로 how='any' 옵션이 적용되는데, 기준이 되는 모든 열들의 행 데이터 중에 NaN값이 하나라도 존재하면 삭제한다는 것이다. how='all' 옵션으로 입력하면 기준이 되는 모든 열들의 행 데이터가 모두 NaN값일 경우에만 삭제가 된다.
총 891개의 행 중 나이 데이터가 누락된 177행을 삭제하고 나머지 714개의 행을 df_age에 저장한다.

〈예제 5-2〉 누락 데이터 제거 (File : example/part5/5.2_dropna.py(이어서 계속))

```
~  ~~~ 생략 ~~~

23  # age 열에 나이 데이터가 없는 모든 행 삭제 - age 열(891개 중 177개의 NaN값)
24  df_age = df.dropna(subset=['age'], how='any', axis=0)
25  print(len(df_age))
```

←왼쪽 코드와 비교

```
# age, embarked 열 기준, 나이 데이터, 정박 데이터가 모두 없는 행을 삭제)
df_all = df_thresh.dropna(subset=['age', 'embarked'], how='all', axis=0)
print(df_all)
print(len(df_all))
```

〈실행 결과〉 코드 23~25라인을 부분 실행

```
714
```

▪ 누락 데이터 치환

– 평균(mean)으로 누락 데이터를 바꿔주는 방법

[예제 5-3] 평균으로 누락 데이터 바꾸기

승객의 나이 데이터가 누락된 행을 제거하지 않고 대신 'age' 열의 나머지 승객의 평균나이로 치환한다. 'age'열에 들어있는 값들의 평균을 계산하여 mean_age에 저장한다.
mean( ) 메소드를 적용하면 NaN을 제외하고 평균을 계산한다. fillna( ) 메소드에 mean_age를 인자로 전달하면 NaN을 찾아서 mean_age 값으로 치환한다.

```
2
3  # 라이브러리 불러오기
4  import seaborn as sns
5
6  # titanic 데이터셋 가져오기
7  df = sns.load_dataset('titanic')
9  # age 열의 첫 10개 데이터 출력(5행에 NaN값)
10 print(df['age'].head(10))
11 print('\n')
12
13 # age 열의 NaN값을 다른 나이 데이터의 평균으로 변경하기
14 mean_age = df['age'].mean(axis=0)    # age 열의 평균 계산(NaN값 제외)
15 df['age'].fillna(mean_age, inplace=True)
16
17 # age 열의 첫 10개 데이터 출력(5행에 NaN값이 평균으로 대체)
18 print(df['age'].head(10))
```

〈실행 결과〉 코드 전부 실행

```
0    22.0
1    38.0
2    26.0
3    35.0
4    35.0
5     NaN
6    54.0
7     2.0
8    27.0
9    14.0
Name: age, dtype: float64


0    22.000000
1    38.000000
2    26.000000
3    35.000000
4    35.000000
5    29.699118
6    54.000000
7     2.000000
8    27.000000
9    14.000000
Name: age, dtype: float64
```

▪ 누락 데이터 치환

– 가장 많이 나타나는 값으로 NaN을 치환하는 방법

[예제 5-4] 가장 많이 나타나는 값으로 바꾸기

승선도시를 나타내는 'embark_town' 열에 있는 NaN을 다른 값으로 바꾼다. 가장 많이 승선한 도시의 이름을 찾아서 NaN을 치환한다. value_counts( ) 메소드를 사용하여 승선도시별 승객 수를 찾고, idxmax( ) 메소드로 가장 큰 값을 갖는 도시(Southampton)를 찾는다. 실행 결과에서 829행의 NaN값을 포함해서 누락 데이터들은 Southampton으로 변경된다.

```
import seaborn as sns

# titanic 데이터셋 가져오기
df = sns.load_dataset('titanic')

# embark_town 열의 829행의 NaN 데이터 출력
print(df['embark_town'][825:830])
print('₩n')

# embark_town 열의 NaN값을 승선도시 중에서 가장 많이 출현한 값으로 치환하기
print(df['embark_town'].value_counts(dropna=True))
most_freq = df['embark_town'].value_counts(dropna=True).idxmax()
print(most_freq)
print('₩n')

df['embark_town'].fillna(most_freq, inplace=True)

# embark_town 열 829행의 NaN 데이터 출력 (NaN 값이 most_freq 값으로 대체)
print(df['embark_town'][825:830])
```

```
825    Queenstown
826    Southampton
827      Cherbourg
828    Queenstown
829            NaN
Name: embark_town, dtype: object


Southampton    644
Cherbourg      168
Queenstown      77
Name: embark_town, dtype: int64
Southampton


825    Queenstown
826    Southampton
827      Cherbourg
828    Queenstown
829    Southampton
Name: embark_town, dtype: object
```

▪ 누락 데이터 치환

– 앞이나 뒤에서 이웃하고 있는 값으로 치환하는 방법

[예제 5-5] 이웃하고 있는 값으로 바꾸기

데이터셋의 특성상 서로 이웃하고 있는 데이터끼리 유사성을 가질 가능성이 높다. Fillna( ) 메소드에 method='ffill' 옵션을 추가하면 NaN이 있는 행의 직전 행에 있는 값으로 바꿔준다. method='bfill'옵션을 사용하면 NaN이 있는 행의 바로 다음 행에 있는 값을 가지고 치환한다.
'ffill'옵션을 사용하여 829행의 NaN값을 바로 앞에 위치한 828행의 Queenstown으로 변경한다.

```
3  # 라이브러리 불러오기
4  import seaborn as sns
5
6  # titanic 데이터셋 가져오기
7  df = sns.load_dataset('titanic')
8
9  # embark_town 열 829행의 NaN 데이터 출력
10 print(df['embark_town'][825:830])
11 print('\n')
12
13 # embark_town 열의 NaN값을 바로 앞에 있는 828행의 값으로 변경하기
14 df['embark_town'].fillna(method='ffill', inplace=True)
15 print(df['embark_town'][825:830])
```

〈실행 결과〉 코드 전부 실행

```
825     Queenstown
826    Southampton
827      Cherbourg
828     Queenstown
829            NaN
Name: embark_town, dtype: object


825     Queenstown
826    Southampton
827      Cherbourg
828     Queenstown
829     Queenstown
Name: embark_town, dtype: object
```

▪ 중복 데이터 확인

[예제 5-6] 중복 데이터 확인

동일한 관측값이 중복되는지 여부, 즉 행의 레코드가 중복되는지 여부를 확인하려면 duplicated( ) 메소드를 이용한다. 이전에 나온 행들과 비교하여 중복되는 행이면 True 반환, 처음 나오는 행에 대해서 False 반환한다.

```
import pandas as pd

# 중복 데이터를 갖는 데이터프레임 만들기
df = pd.DataFrame({'c1':['a', 'a', 'b', 'a', 'b'],
                   'c2':[1, 1, 1, 2, 2],
                   'c3':[1, 1, 2, 2, 2]})
print(df)
print('₩n')

# 데이터프레임 전체 행 데이터 중에서 중복값 찾기
sr_dup = df.duplicated()
print(sr_dup)
print(type(sr_dup))
print('₩n')
```

```
  c1  c2  c3
0  a   1   1
1  a   1   1
2  b   1   2
3  a   2   2
4  b   2   2


0    False
1     True
2    False
3    False
4    False
dtype: bool
<class 'pandas.core.series.Series'>
```

	c1	c2	c3
0	a	1	1
1	a	1	1
2	b	1	2
3	a	2	2
4	b	2	2

▪ 중복 데이터 확인

[예제 5-6] 중복 데이터 확인

데이터프레임의 하나의 열에도, duplicated( ) 메소드를 적용할 수 있다.
데이터프레임 df의 'c2'열은 정수 1과 2로 구성된다. 1이 처음 나타난 0행과 2가 처음 나타난 행 3행을 제외하고 나머지 1, 2, 4행은 이전에 나온 행과 중복되므로 True가 된다.
1, 2행은 데이터 1을 가진 0행과 중복되고, 4행은 데이터 2를 가진 3행과 중복된다.

```
18  # 데이터프레임의 특정 열 데이터에서 중복값 찾기
19  col_dup = df['c2'].duplicated()
20  print(col_dup)
```

〈실행 결과〉 코드 18~20라인을 부분 실행

```
0    False
1     True
2     True
3    False
4     True
Name: c2, dtype: bool
```

▪ 중복 데이터 제거

[예제 5-7] 중복 데이터 제거

drop_duplicates( ) 메소드의 subset 옵션에 열 이름의 리스트를 전달할 수 있다. 데이터의 중복 여부를 판별할 때, subset 옵션에 해당하는 열을 기준으로 판단한다.
데이터프레임 df의 'c2', 'c3' 열을 기준으로 판별하면 0행과 1행, 3행과 4행의 데이터가 각각 중복된다. 0행과 3행은 처음 나타난 데이터라서 제외하고, 1행과 4행의 데이터만 중복으로 판별하고 삭제한다.

```
18  # c2, c3열을 기준으로 중복 행 제거
19  df3 = df.drop_duplicates(subset=['c2', 'c3'])
20  print(df3)
```

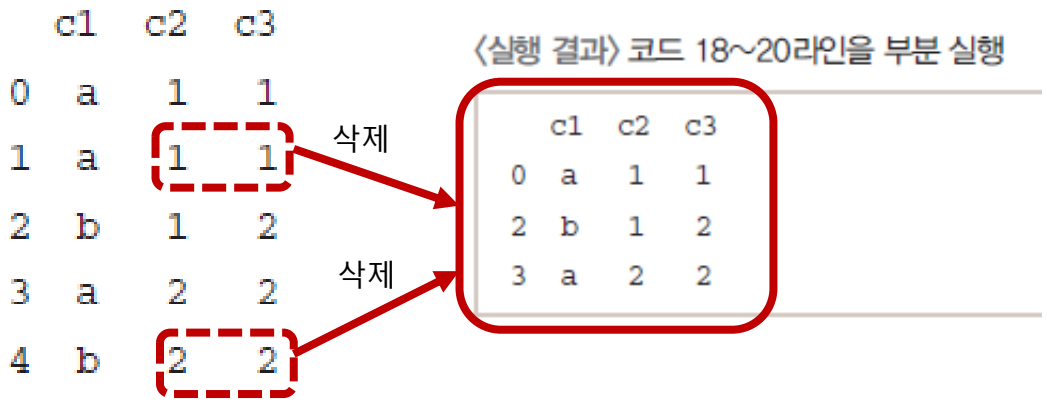

▪ 중복 데이터 제거

[예제 5-7] 중복 데이터 제거

중복 데이터를 제거하는 명령에는 drop_duplicates( ) 메소드가 있다. 중복되는 행을 제거하고 고유한 관측값을 가진 행들만 남긴다. 원본 객체를 변경하려면 inplace=True 옵션을 추가한다. 1행 데이터는 앞에 이웃하고 있는 0행의 데이터와 중복되므로 제거된다.

```
3  # 라이브러리 불러오기
4  import pandas as pd
5
6  # 중복 데이터를 갖는 데이터프레임 만들기
7  df = pd.DataFrame({'c1':['a', 'a', 'b', 'a', 'b'],
8                     'c2':[1, 1, 1, 2, 2],
9                     'c3':[1, 1, 2, 2, 2]})
10 print(df)
11 print('\n')
12
13 # 데이터프레임에서 중복 행 제거
14 df2 = df.drop_duplicates()
15 print(df2)
16 print('\n')
```

〈실행 결과〉 코드 1~16라인을 부분 실행

```
  c1  c2  c3
0  a   1   1
1  a   1   1
2  b   1   2
3  a   2   2
4  b   2   2


  c1  c2  c3
0  a   1   1
2  b   1   2
3  a   2   2
4  b   2   2
```

▪ 단위 환산

- 같은 데이터셋 안에서 서로 다른 측정 단위를 사용한다면, 전체 데이터의 일관성 측면에서 문제가 발생함 => 측정 단위를 동일하게 맞출 필요가 있음
- 외국 데이터를 가져오면 국내에서 잘 사용하지 않는 도량형 단위를 사용하는 경우가 많음
- 영미권에서 주로 사용하는 마일, 야드, 온스 등이 있는데 한국에서 사용하는 미터, 평, 그램 등으로 변환하는 것이 좋음
- UCI 자동차 연비 데이터셋에서의 'mpg' 열은 영미권에서 사용하는 '갤런당 마일(mile per gallon)' 단위로 연비를 표시하고 있음

  => '리터당 키로미터(km/L)' 단위로 변환해봄

  (1마일은 1.60934km이고, 1갤런은 3.78541리터임) -> 1mpg = 0.425km/L

▪ 단위 환산

[예제 5-8] 단위 환산

0행에 들어 있는 차량의 연비는 18mpg이다. 한국식 연비 표현으로 변환한 'kpl'열의 0행에 해당하는 값은 리터당 7.65킬로미터이다. round(2) 명령은 소수점 아래 둘째자리 반올림을 뜻한다.

```
3  # 라이브러리 불러오기
4  import pandas as pd
5
6  # read_csv() 함수로 df 생성
7  df = pd.read_csv('./auto-mpg.csv', header=None)
8
9  # 열 이름 지정
10 df.columns = ['mpg','cylinders','displacement','horsepower','weight',
11              'acceleration','model year','origin','name']
12 print(df.head(3))
13 print('\n')
14
15 # mpg(mile per gallon)를 kpl(kilometer per liter)로 변환(mpg_to_kpl = 0.425)
16 mpg_to_kpl = 1.60934/3.78541
17
18 # mpg 열에 0.425를 곱한 결과를 새로운 열(kpl)에 추가
19 df['kpl'] = df['mpg'] * mpg_to_kpl
20 print(df.head(3))
21 print('\n')
22
23 # kpl 열을 소수점 아래 둘째자리에서 반올림
24 df['kpl'] = df['kpl'].round(2)
25 print(df.head(3))
```

〈예제 5-8〉 코드 전부 실행

```
    mpg  cylinders           ...              origin                       name
0  18.0          8           ...                   1  chevrolet chevelle malibu
1  15.0          8           ...                   1          buick skylark 320
2  18.0          8           ...                   1         plymouth satellite

[3 rows x 9 columns]


    mpg  cylinders    ...                        name       kpl
0  18.0          8    ...     chevrolet chevelle malibu  7.652571
1  15.0          8    ...             buick skylark 320  6.377143
2  18.0          8    ...            plymouth satellite  7.652571

[3 rows x 10 columns]


    mpg  cylinders  displacement  ...  origin                       name   kpl
0  18.0          8         307.0  ...       1  chevrolet chevelle malibu  7.65
1  15.0          8         350.0  ...       1          buick skylark 320  6.38
2  18.0          8         318.0  ...       1         plymouth satellite  7.65

[3 rows x 10 columns]
```

▪ 자료형 환산

[예제 5-9] 자료형 변환

숫자가 문자열(object)로 저장된 경우에 숫자형(int 또는 float)으로 변환해야 한다.
dtypes 속성을 사용하여 데이터프레임을 구성하는 각 열의 자료형을 확인한다.
dtypes 속성 대신 info( ) 메소드를 사용해도 각 열의 자료형을 확인할 수 있다.
엔진 출력을 나타내는 **'horsepower'열은 숫자형이 적절**하고, **출시연도를 나타내는 'model_year'열과 출시국가를 뜻하는 'origin'열은 카테고리를 나타내는 범주형이 적절하므로** 변환한다.

```
3  # 라이브러리 불러오기
4  import pandas as pd
5
6  # read_csv() 함수로 df 생성
7  df = pd.read_csv('./auto-mpg.csv', header=None)
8
9  # 열 이름 지정
10 df.columns = ['mpg','cylinders','displacement','horsepower','weight',
11               'acceleration','model year','origin','name']
12
13 # 각 열의 자료형 확인
14 print(df.dtypes)
15 print('\n')
```

〈실행 결과〉 코드 1~15라인을 부분 실행

```
mpg             float64
cylinders         int64
displacement    float64
horsepower       object
weight          float64
acceleration    float64
model year        int64
origin            int64
name             object
dtype: object
```

▪ 자료형 환산

[예제 5-9] 자료형 변환

'horsepower' 열은 현재 object 자료형이나, 엔진 출력의 크기를 나타내는 데이터이므로 숫자형으로 변환해주는 것이 적절하다. 고유값 중 3번째 줄 중간에 문자열 '?'가 섞여 있어서, 이 때문에 CSV 파일을 데이터프레임으로 변환하는 과정에서 문자열로 인식된 것으로 보인다. '?'는 삭제하고 나머지 값은 모두 숫자형으로 변환하는 것이 적절하다.

```
17  # horsepower 열의 고유값 확인
18  print(df['horsepower'].unique())
19  print('\n')
```

〈실행 결과〉 코드 17~19라인을 부분 실행

```
['130.0' '165.0' '150.0' '140.0' '198.0' '220.0' '215.0' '225.0' '190.0'
 '170.0' '160.0' '95.00' '97.00' '85.00' '88.00' '46.00' '87.00' '90.00'
 '113.0' '200.0' '210.0' '193.0' '?' '100.0' '105.0' '175.0' '153.0'
 '180.0' '110.0' '72.00' '86.00' '70.00' '76.00' '65.00' '69.00' '60.00'
 '80.00' '54.00' '208.0' '155.0' '112.0' '92.00' '145.0' '137.0' '158.0'
 '167.0' '94.00' '107.0' '230.0' '49.00' '75.00' '91.00' '122.0' '67.00'
 '83.00' '78.00' '52.00' '61.00' '93.00' '148.0' '129.0' '96.00' '71.00'
 '98.00' '115.0' '53.00' '81.00' '79.00' '120.0' '152.0' '102.0' '108.0'
 '68.00' '58.00' '149.0' '89.00' '63.00' '48.00' '66.00' '139.0' '103.0'
 '125.0' '133.0' '138.0' '135.0' '142.0' '77.00' '62.00' '132.0' '84.00'
 '64.00' '74.00' '116.0' '82.00']
```

▪ 자료형 환산

[예제 5-9] 자료형 변환

'horsepower' 열의 문자열 '?'를 NaN값으로 변환한다. dropna(axis=0) 메소드로 NaN값이 들어 있는 모든 행을 삭제한다. 'horsepower' 열에는 숫자형으로 변환 가능한 값들만 남는다.
astype('float')명령을 이용하여 문자열을 실수형으로 변환한다. 실수형 대신 정수형으로 변환하려면, 'float' 대신 'int'를 입력한다. dtypes 속성을 사용하여 변환된 결과가 맞는지 확인한다.

```
21  # 누락 데이터('?') 삭제
22  import numpy as np
23  df['horsepower'].replace('?', np.nan, inplace=True)       # '?'을 np.nan으로 변경
24  df.dropna(subset=['horsepower'], axis=0, inplace=True)    # 누락 데이터 행 삭제
25  df['horsepower'] = df['horsepower'].astype('float')       # 문자열을 실수형으로 변환
26
27  # horsepower 열의 자료형 확인
28  print(df['horsepower'].dtypes)
```

〈실행 결과〉 코드 21~28라인을 부분 실행

```
float64
```

▪ 자료형 환산

[예제 5-9] 자료형 변환

'origin' 열에는 정수형 데이터 1, 2, 3이 들어 있지만, 실제로는 국가이름인 'USA, EU, JPN'을 뜻한다. replace( ) 메소드를 사용하여 각 숫자 데이터를 국가이름으로 바꿔주면 문자열을 나타내는 object 자료형으로 자동 변경된다.

```
31  # origin 열의 고유값 확인
32  print(df['origin'].unique())
33
34  # 정수형 데이터를 문자형 데이터로 변환
35  df['origin'].replace({1:'USA', 2:'EU', 3:'JPN'}, inplace=True)
36
37  # origin 열의 고유값과 자료형 확인
38  print(df['origin'].unique())
39  print(df['origin'].dtypes)
```

〈실행 결과〉 코드 31~39라인을 부분 실행

```
[1 3 2]
['USA' 'JPN' 'EU']
object
```

▪ 자료형 환산

[예제 5-9] 자료형 변환

'origin' 열의 국가이름은 문자열 데이터이다. 값을 확인해보면 3개의 국가이름이 계속 반복된다. 유한 개의 고유값이 반복적으로 나타나는 경우에는 범주형 데이터로 표현하는 것이 효율적이다. astype('category')메소드를 이용하면 범주형 데이터로 변환한다. 범주형을 다시 문자열로 변환하려면 astype('str') 메소드를 사용한다.

```
42  # 문자열을 범주형으로 변환
43  df['origin'] = df['origin'].astype('category')
44  print(df['origin'].dtypes)
45
46  # 범주형을 문자열로 다시 변환
47  df['origin'] = df['origin'].astype('str')
48  print(df['origin'].dtypes)
```

〈실행 결과〉 코드 42~48라인을 부분 실행

```
category
object
```

▪ 자료형 환산

[예제 5-9] 자료형 변환

sample( ) 메소드로 'model year'열에서 무작위로 3개의 행을 선택해서 출력해본다. 81, 71, 77과 같이 모델 출시연도가 숫자로 기록되어 있고, 자료형은 정수형을 나타내는 int64이다.
연도를 뜻하기 때문에 숫자형으로 남겨둬도 무방하지만 연도는 시간적인 순서의 의미는 있으나 숫자의 상대적인 크기는 별 의미가 없다. 데이터는 숫자 형태를 갖더라도 자료형은 범주형으로 표현하는 것이 적절하다.

```
50  # model year 열의 정수형을 범주형으로 변환
51  print(df['model year'].sample(3))
52  df['model year'] = df['model year'].astype('category')
53  print(df['model year'].sample(3))
```

〈실행 결과〉 코드 50~53라인을 부분 실행

```
365    81
44     71
218    77
Name: model year, dtype: int64
332    80
21     70
360    81
Name: model year, dtype: category
Categories (13, int64): [70, 71, 72, 73, ..., 79, 80, 81, 82]
```

▪ 구간 분할

- 데이터 분석 알고리즘에 따라서는 연속 데이터를 그대로 사용하기 보다는 일정한 구간(bin)으로 나눠서 분석하는 것이 효율적인 경우가 있음
- 가격, 비용, 효율 등 연속적인 값을 일정한 수준이나 정도를 나타내는 이산적인 값으로 나타내어 구간별 차이를 드러내는 것임
- 연속 변수를 일정한 구간으로 나누고, 각 구간을 범주형 이산 변수로 변환하는 과정을 구간 분할(binning)이라 함
- 판다스 cut( ) 함수를 이용하면 연속 데이터를 여러 구간으로 나누고 범주형 데이터로 변환할 수 있음

[그림 5-1] 구간 분할 경계값 구하기

▪ 데이터 구간 분할

[예제 5-10] 데이터 구간 분할

경계값을 구하는 방법 중에서 NumPy 라이브러리의 histogram( ) 함수를 활용하는 방법을 설명한다.
나누려는 구간(bin) 개수를 bins 옵션에 입력하면 각 구간에 속하는 값의 개수(count)와 경계값 리스트(bin_dividers)를 반환한다.
모두 4개의 경계값을 생성하고 3개의 구간이 만들어진다(46~107.3 구간, 107.3~168.6 구간, 168.6~230 구간)

```
# 라이브러리 불러오기
import pandas as pd
import numpy as np

# read_csv() 함수로 df 생성
df = pd.read_csv('./auto-mpg.csv', header=None)

# 열 이름을 지정
df.columns = ['mpg','cylinders','displacement','horsepower','weight',
              'acceleration','model year','origin','name']

# horsepower 열의 누락 데이터('?') 삭제하고 실수형으로 변환
df['horsepower'].replace('?', np.nan, inplace=True)      # '?'을 np.nan으로 변경
df.dropna(subset=['horsepower'], axis=0, inplace=True)   # 누락데이터 행을 삭제
df['horsepower'] = df['horsepower'].astype('float')      # 문자열을 실수형으로 변환

# np.histogram 함수로 3개의 bin으로 나누는 경계 값의 리스트 구하기
count, bin_dividers = np.histogram(df['horsepower'], bins=3)
print(count, bin_dividers)
```

```
[257 103  32] [ 46.         107.33333333 168.66666667 230.        ]
```

▪ 데이터 구간 분할

[예제 5-10] 데이터 구간 분할

판다스 cut( ) 함수를 이용하면 연속 데이터를 여러 구간으로 나누고 범주형 데이터로 변환할 수 있다.
판다스 cut( ) 함수의 옵션을 설정한다. 경계값의 리스트(bin_dividers)를 bins 옵션에 할당하고 각 구간의 이름(bin_names)을 labels 옵션에 할당한다.

```
23  # 3개의 bin에 이름 지정
24  bin_names = ['저출력', '보통출력', '고출력']
25
26  # pd.cut 함수로 각 데이터를 3개의 bin에 할당
27  df['hp_bin'] = pd.cut(x=df['horsepower'],        # 데이터 배열
28                        bins=bin_dividers,         # 경계값 리스트
29                        labels=bin_names,          # bin 이름
30                        include_lowest=True)       # 첫 경계값 포함
31
32  # horsepower 열, hp_bin 열의 첫 15행 출력
33  print(df[['horsepower', 'hp_bin']].head(15))
```

〈실행 결과〉 코드 23~33라인을 부분 실행

	horsepower	hp_bin
0	130.0	보통출력
1	165.0	보통출력
2	150.0	보통출력
3	150.0	보통출력
4	140.0	보통출력
5	198.0	고출력
6	220.0	고출력
7	215.0	고출력
8	225.0	고출력
9	190.0	고출력
10	170.0	고출력
11	160.0	보통출력
12	150.0	보통출력
13	225.0	고출력
14	95.0	저출력

- **더미 변수**
  - 카테고리를 나타내는 범주형 데이터를 회귀분석 등 머신러닝 알고리즘에 바로 사용할 수 없는 경우가 있는데, 컴퓨터가 인식 가능한 입력값으로 변환해야 함

    => 숫자 0 또는 1로 표현되는 더미 변수(dummy variable)를 사용함

    (여기서의 0과 1은 수의 크고 작음을 나타내지 않고, 어떤 특성이 있는지 없는지 여부만을 표시함)

▪ 더미 변수

[예제 5-11] 더미 변수

판다스 get_dummies( ) 함수를 사용하면, 범주형 변수의 모든 고유값을 각각 새로운 더미 변수로 변환한다.
'hp_bin' 열의 고유값 3개가 각각 새로운 더미 변수 열의 이름이 된다. 각 행 별로, 범주형 변수가 본래 속해 있던 위치에는 1이 입력되고, 속하지 않았던 위치에는 0이 입력된다.

```
19  # np.histogram 함수로 3개의 bin으로 나누는 경계값의 리스트 구하기
20  count, bin_dividers = np.histogram(df['horsepower'], bins=3)
21
22  # 3개의 bin에 이름 지정
23  bin_names = ['저출력', '보통출력', '고출력']
24
25  # pd.cut으로 각 데이터를 3개의 bin에 할당
26  df['hp_bin'] = pd.cut(x=df['horsepower'],        # 데이터 배열
27                        bins=bin_dividers,        # 경계값 리스트
28                        labels=bin_names,         # bin 이름
29                        include_lowest=True)      # 첫 경계값 포함
30
31  # hp_bin 열의 범주형 데이터를 더미 변수로 변환
32  horsepower_dummies = pd.get_dummies(df['hp_bin'])
33  print(horsepower_dummies.head(15))
```

df['hp_bin']

0	보통출력
1	보통출력
2	보통출력
3	보통출력
4	보통출력
5	고출력
6	고출력
7	고출력
8	고출력
9	고출력
10	고출력
11	보통출력
12	보통출력
13	고출력
14	저출력

〈실행 결과〉 코드 전부 실행

	저출력	보통출력	고출력
0	0	1	0
1	0	1	0
2	0	1	0
3	0	1	0
4	0	1	0
5	0	0	1
6	0	0	1
7	0	0	1
8	0	0	1
9	0	0	1
10	0	0	1
11	0	1	0
12	0	1	0
13	0	0	1
14	1	0	0

▪ 더미 변수

[예제 5-12] 원핫-인코딩

sklearn 라이브러리를 이용해서 원핫인코딩을 처리할 수 있다.
데이터프레임 df의 'hp_bin'열에 들어 있는 범주형 데이터를 0, 1을 원소로 갖는 원핫벡터로 변환한다.
결과는 선형대수학에서 정의하는 희소행렬(sparse matrix)로 정리된다.
1차원 벡터를 2차원 행렬로 변환하고 다시 희소행렬로 변환한다. 희소행렬은 (행, 열) 좌표와 값 형태로 정리된다. (0,1)은 0행의 1열 위치를 말하고, 데이터 값은 숫자 1 또는 0이 입력된다.

```
31  # sklern 라이브러리 불러오기
32  from sklearn import preprocessing
33
34  # 전처리를 위한 encoder 객체 만들기
35  label_encoder = preprocessing.LabelEncoder()          # label encoder 생성
36  onehot_encoder = preprocessing.OneHotEncoder()        # one hot encoder 생성
37
38  # label encoder로 문자열 범주를 숫자형 범주로 변환
39  onehot_labeled = label_encoder.fit_transform(df['hp_bin'].head(15))
40  print(onehot_labeled)
41  print(type(onehot_labeled))
42
43  # 2차원 행렬로 형태 변경
44  onehot_reshaped = onehot_labeled.reshape(len(onehot_labeled), 1)
45  print(onehot_reshaped)
46  print(type(onehot_reshaped))
```

〈실행 결과〉 코드 전부 실행

```
[1 1 1 1 1 0 0 0 0 0 0 1 1 0 2]
<class 'numpy.ndarray'>
[[1]
 [1]
 [1]
 [1]
 [1]
 [0]
 [0]
 [0]
 [0]
 [0]
 [0]
 [1]
 [1]
 [0]
 [2]]
<class 'numpy.ndarray'>
```

▪ 더미 변수

[예제 5-12] 원핫-인코딩

sklearn 라이브러리를 이용해서 원핫인코딩을 편하게 처리할 수 있다.
데이터프레임 df의 'hp_bin'열에 들어 있는 범주형 데이터를 0, 1을 원소로 갖는 원핫벡터로 변환한다.
결과는 선형대수학에서 정의하는 희소행렬(sparse matrix)로 정리된다.
1차원 벡터를 **2차원 행렬로 변환하고 다시 희소행렬로 변환한다**. 희소행렬은 (행, 열) 좌표와 값 형태로 정리된다. (0,1)은 0행의 1열 위치를 말하고, 데이터 값은 숫자 1, 0이 입력된다.

```
48  # 희소행렬로 변환
49  onehot_fitted = onehot_encoder.fit_transform(onehot_reshaped)
50  print(onehot_fitted)
51  print(type(onehot_fitted))
```

```
[[1]
 [1]
 [1]
 [1]
 [1]
 [0]
 [0]
 [0]
 [0]
 [0]
 [0]
 [1]
 [1]
 [0]
 [2]]
<class 'numpy.ndarray'>
```

???

```
  (0, 1)        1.0
  (1, 1)        1.0
  (2, 1)        1.0
  (3, 1)        1.0
  (4, 1)        1.0
  (5, 0)        1.0
  (6, 0)        1.0
  (7, 0)        1.0
  (8, 0)        1.0
  (9, 0)        1.0
  (10, 0)       1.0
  (11, 1)       1.0
  (12, 1)       1.0
  (13, 0)       1.0
  (14, 2)       1.0
<class 'scipy.sparse._csr.csr_matrix'>
```

▪ 더미 변수

[예제 5-12] 원핫-인코딩

sklearn 라이브러리를 이용해서 원핫인코딩을 편하게 처리할 수 있다.
데이터프레임 df의 'hp_bin'열에 들어 있는 범주형 데이터를 0, 1을 원소로 갖는 원핫벡터로 변환한다.
결과는 선형대수학에서 정의하는 희소행렬(sparse matrix)로 정리된다.
1차원 벡터를 **2차원 행렬로 변환하고 다시 희소행렬로 변환한다**. 희소행렬은 (행, 열) 좌표와 값 형태로 정리된다. (0,1)은 0행의 1열 위치를 말하고, 데이터 값은 숫자 1, 0이 입력된다.

```
48  # 희소행렬로 변환
49  onehot_fitted = onehot_encoder.fit_transform(onehot_reshaped)
50  print(onehot_fitted)
51  print(type(onehot_fitted))
```

```
[[1]
 [1]
 [1]
 [1]
 [1]
 [0]
 [0]
 [0]
 [0]
 [0]
 [0]
 [1]
 [1]
 [0]
 [2]]
<class 'numpy.ndarray'>
```

```
[[0. 1. 0.]
 [0. 1. 0.]
 [0. 1. 0.]
 [0. 1. 0.]
 [0. 1. 0.]
 [1. 0. 0.]
 [1. 0. 0.]
 [1. 0. 0.]
 [1. 0. 0.]
 [1. 0. 0.]
 [1. 0. 0.]
 [1. 0. 0.]
 [0. 1. 0.]
 [0. 1. 0.]
 [1. 0. 0.]
 [0. 0. 1.]]
<class 'numpy.ndarray'>
```

```
  (0, 1)        1.0
  (1, 1)        1.0
  (2, 1)        1.0
  (3, 1)        1.0
  (4, 1)        1.0
  (5, 0)        1.0
  (6, 0)        1.0
  (7, 0)        1.0
  (8, 0)        1.0
  (9, 0)        1.0
  (10, 0)       1.0
  (11, 1)       1.0
  (12, 1)       1.0
  (13, 0)       1.0
  (14, 2)       1.0
<class 'scipy.sparse._csr.csr_matrix'>
```

▪ 정규화

– 각 변수(데이터프레임의 열)에 들어 있는 숫자 데이터의 상대적 크기 차이 때문에 머신러닝 분석 결과가 달라질 수 있음

예) A변수 (0~1000범위의 값), B변수 (0~1범위의 값)

=> 상대적으로 큰 숫자 값을 갖는 A 변수의 영향이 더 커짐

– 숫자 데이터의 상대적인 크기 차이를 제거할 필요가 있음

– 정규화(normalization) : 각 열(변수)에 속하는 데이터 값을 동일한 크기 기준으로 나눈 비율로 나타내는 것

– 정규화 과정을 거친 데이터의 범위는 0~1 또는 -1~1이 됨

▪ 정규화

[예제 5-13] 정규화

각 열(변수)의 데이터를 해당 열의 최대값(의 절대값)으로 나누는 방법이 있다.
어떤 열의 원소 값을 그 열의 최대값으로 나누면 가장 큰 값은 최대값 자기자신을 나눈 1이다.
'horsepower'열의 원래 최대값은 230인데 최대값을 정규화하면 1이 된다.

```
3  # 라이브러리 불러오기
4  import pandas as pd
5  import numpy as np
6
7  # read_csv() 함수로 df 생성
8  df = pd.read_csv('./auto-mpg.csv', header=None)
9
10 # 열 이름 지정
11 df.columns = ['mpg','cylinders','displacement','horsepower','weight',
12               'acceleration','model year','origin','name']
13
14 # horsepower 열의 누락 데이터('?') 삭제하고 실수형으로 변환
15 df['horsepower'].replace('?', np.nan, inplace=True)       # '?'을 np.nan으로 변경
16 df.dropna(subset=['horsepower'], axis=0, inplace=True)    # 누락 데이터 행 삭제
17 df['horsepower'] = df['horsepower'].astype('float')      # 문자열을 실수형으로 변환
18
19 # horsepower 열의 통계 요약 정보로 최대값(max) 확인
20 print(df.horsepower.describe())
21 print('\n')
22
23 # horsepower 열의 최대값의 절대값으로 모든 데이터를 나눠서 저장
24 df.horsepower = df.horsepower/abs(df.horsepower.max())
25
26 print(df.horsepower.head())
27 print('\n')
28 print(df.horsepower.describe())
```

〈실행 결과〉 코드 전부 실행

```
count    392.000000
mean     104.469388
std       38.491160
min       46.000000
25%       75.000000
50%       93.500000
75%      126.000000
max      230.000000
Name: horsepower, dtype: float64


0    0.565217
1    0.717391
2    0.652174
3    0.652174
4    0.608696
Name: horsepower, dtype: float64


count    392.000000
mean       0.454215
std        0.167353
min        0.200000
25%        0.326087
50%        0.406522
75%        0.547826
max        1.000000
Name: horsepower, dtype: float64
```

▪ 정규화

[예제 5-14] 정규화

각 열별로 '각 데이터에서 해당 열의 최소값을 뺀 값을 분자'로 하고, '해당 열의 최대값과 최소값의 차를 분모'로 하여 계산하는 방법이다. 가장 큰 값은 1, 가장 작은 값은 0이 된다.

```
19  # horsepower 열의 통계 요약 정보로 최대값(max)과 최소값(min) 확인
20  print(df.horsepower.describe())
21  print('\n')
22
23  # horsepower 열의 최대값의 절대값으로 모든 데이터를 나눠서 저장
24  min_x = df.horsepower - df.horsepower.min()
25  min_max = df.horsepower.max() - df.horsepower.min()
26  df.horsepower = min_x/min_max
27
28  print(df.horsepower.head())
29  print('\n')
30  print(df.horsepower.describe())
```

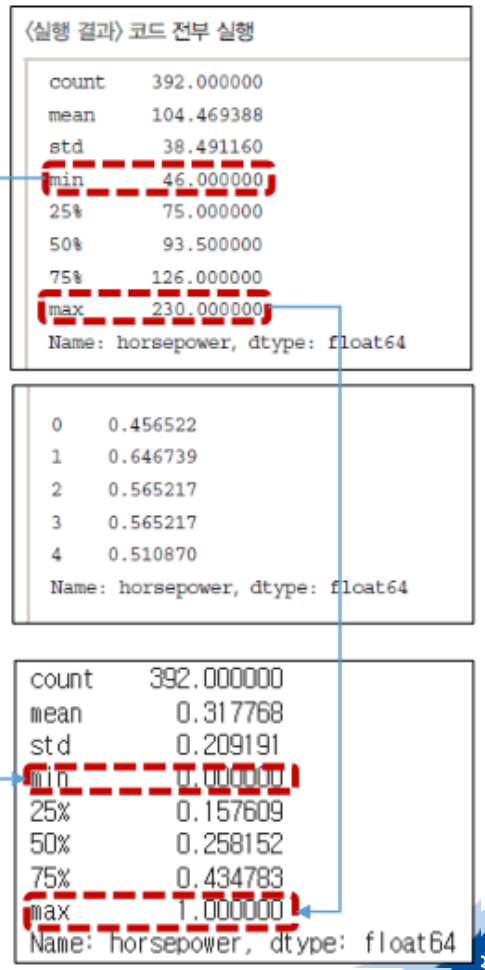

▪ 시계열 데이터

주식, 환율 등 금융 데이터를 다루기 위해 개발된 판다스는 시계열(time series) 데이터를 다루는 여러 가지 유용한 기능을 제공한다. 특히 시계열 데이터를 데이터프레임의 행 인덱스로 사용하면, 시간으로 기록된 데이터를 분석하는 것이 매우 편리하다.

판다스의 시간 표시 방식 중에서 시계열 데이터 표현에 자주 이용되는 두 가지 유형을 알아보자. 특정한 시점을 기록하는 Timestamp와 두 시점 사이의 일정한 기간을 나타내는 Period가 있다.

(a) 타임스탬프(Timestamp)

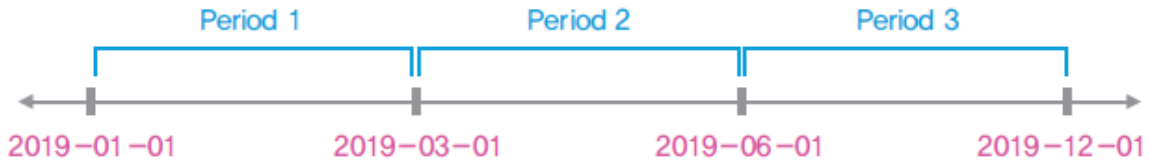

(b) 피리어드(Period)

[그림 5-2] 판다스 시간 표시

▪ 문자열을 Timestamp로 변환1

판다스 to_datetime() 함수를 사용하면 문자열 등 다른 자료형을 판다스 Timestamp를 나타내는 datetime64 자료형으로 변환 가능하다.

주식 시장에서 거래되는 A 종목의 거래 데이터를 정리한 CSV 파일[4]을 read_csv() 함수를 이용하여 불러온다. head() 메소드로 데이터프레임의 일부를 살펴보면, 'Date' 열에 날짜 데이터가 들어 있다. info() 메소드로 해당 열의 자료형을 확인하면 문자열(object)임을 알 수 있다.

[예제 5-15]

```
4  import pandas as pd
5
6  # read_csv() 함수로 CSV 파일을 가져와서 df로 변환
7  df = pd.read_csv('stock-data.csv')
8
9  # 데이터 내용 및 자료형 확인
10 print(df.head())
11 print('\n')
12 print(df.info())
```

〈실행 결과〉 코드 1~12라인을 부분 실행

```
         Date  Close  Start   High    Low  Volume
0  2018-07-02  10100  10850  10900  10000  137977
1  2018-06-29  10700  10550  10900   9990  170253
2  2018-06-28  10400  10900  10950  10150  155769
3  2018-06-27  10900  10800  11050  10500  133548
4  2018-06-26  10800  10900  11000  10700   63039


<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20 entries, 0 to 19
Data columns (total 6 columns):
Date      20 non-null object
Close     20 non-null int64
Start     20 non-null int64
High      20 non-null int64
Low       20 non-null int64
Volume    20 non-null int64
dtypes: int64(5), object(1)
memory usage: 920.0+ bytes
None
```

▪ 문자열을 Timestamp로 변환2

'Date' 열의 날짜 데이터를 판다스 Timestamp 객체로 바꿔본다. 'Date' 열을 to_datetime() 함수의 인자로 전달하면 문자열(object) 데이터를 datetime64 자료형으로 변환한다. 변환된 데이터를 'new_Date' 열에 담아서 데이터프레임 df에 추가한다.

[예제 5-15]

```
14  # 문자열 데이터(시리즈 객체)를 판다스 Timestamp로 변환
15  df['new_Date'] = pd.to_datetime(df['Date'])    # df에 새로운 열로 추가
16
17  # 데이터 내용 및 자료형 확인
18  print(df.head())
19  print('\n')
20  print(df.info())
21  print('\n')
22  print(type(df['new_Date'][0]))
```

〈실행 결과〉 코드 14~22라인을 부분 실행

```
         Date  Close  Start   High    Low  Volume   new_Date
0  2018-07-02  10100  10850  10900  10000  137977 2018-07-02
1  2018-06-29  10700  10550  10900   9990  170253 2018-06-29
2  2018-06-28  10400  10900  10950  10150  155769 2018-06-28
3  2018-06-27  10900  10800  11050  10500  133548 2018-06-27
4  2018-06-26  10800  10900  11000  10700   63039 2018-06-26


<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20 entries, 0 to 19
Data columns (total 7 columns):
Date        20 non-null object
Close       20 non-null int64
Start       20 non-null int64
High        20 non-null int64
Low         20 non-null int64
Volume      20 non-null int64
new_Date    20 non-null datetime64[ns]
dtypes: datetime64[ns](1), int64(5), object(1)
memory usage: 1.1+ KB
None


<class 'pandas._libs.tslibs.timestamps.Timestamp'>
```

▪ 문자열을 Timestamp로 변환3

'new_Date' 열을 데이터프레임 df의 행 인덱스로 설정하고, 'Date' 열을 제거한다. 이렇게 시계열 값을 행 인덱스로 지정하면 판다스는 DatetimeIndex로 저장한다. 이처럼 시계열 인덱스 클래스를 지원하기 때문에 시간 순서에 맞춰 인덱싱 또는 슬라이싱 하기가 편리하다.

[예제 5-15]

```
24  # 시계열 값으로 변환된 열을 새로운 행 인덱스로 지정. 기존 날짜 열은 삭제
25  df.set_index('new_Date', inplace=True)
26  df.drop('Date', axis=1, inplace=True)
27
28  # 데이터 내용 및 자료형 확인
29  print(df.head())
30  print('\n')
31  print(df.info())
```

〈실행 결과〉 코드 24~31라인을 부분 실행

```
            Close  Start  High    Low  Volume
new_Date
2018-07-02  10100  10850  10900  10000  137977
2018-06-29  10700  10550  10900   9990  170253
2018-06-28  10400  10900  10950  10150  155769
2018-06-27  10900  10800  11050  10500  133548
2018-06-26  10800  10900  11000  10700   63039


<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 20 entries, 2018-07-02 to 2018-06-01
Data columns (total 5 columns):
Close     20 non-null int64
Start     20 non-null int64
High      20 non-null int64
Low       20 non-null int64
Volume    20 non-null int64
dtypes: int64(5)
memory usage: 960.0 bytes
None
```

▪ Timestamp를 Period로 변환

판다스 to_period( )함수를 이용하면 Timestamp 객체를 일정한 기간을 나타내는 Period 객체로 변환할 수 있다.
freq 옵션을 D로 지정할 경우 1일의 기간, M은 1개월의 기간, A는 1년의 기간을 나타내는 데, 이때 1년은 12월에 끝나는 걸로 전제한다.

[예제 5-16]

```
4  import pandas as pd
5
6  # 날짜 형식의 문자열로 구성되는 리스트 정의
7  dates = ['2019-01-01', '2020-03-01', '2021-06-01']
10 ts_dates = pd.to_datetime(dates)
11 print(ts_dates)
12 print('\n')
13
14 # Timestamp를 Period로 변환
15 pr_day = ts_dates.to_period(freq='D')
16 print(pr_day)
17 pr_month = ts_dates.to_period(freq='M')
18 print(pr_month)
19 pr_year = ts_dates.to_period(freq='A')
20 print(pr_year)
```

〈실행 결과〉 코드 전부 실행

```
DatetimeIndex(['2019-01-01', '2020-03-01', '2021-06-01'], dtype='datetime64[ns]', freq=-
None)
PeriodIndex(['2019-01-01', '2020-03-01', '2021-06-01'], dtype='period[D]', freq='D')
PeriodIndex(['2019-01', '2020-03', '2021-06'], dtype='period[M]', freq='M')
PeriodIndex(['2019', '2020', '2021'], dtype='period[A-DEC]', freq='A-DEC')
```

▪ Timestamp 배열 만들기1

판다스 date_range( )함수를 이용하면 여러 개의 Timestamp가 들어 있는 배열 형태의 시계열 데이터를 만들 수 있다.
예제에서, 생성할 Timestamp들의 시작 옵션은 '2019-01-01'으로 설정하고, 끝 옵션은 None으로 설정하였다. period 옵션은 6으로 설정하여 Timestamp를 6개 생성하도록 하였다. freq 옵션은 MS로 설정하였는 데 이는 월의 시작(Month start)이다 .
정리하면, 2019년 1월1일을 시작으로 한달 간격으로 하여, 6개의 월별 시작 시점을 원소로 가지는 Timestamp 배열을 생성한다는 의미이다.

[예제 5-17]

```
4  import pandas as pd
5
6  # Timestamp의 배열 만들기 - 월 간격, 월의 시작일 기준
7  ts_ms = pd.date_range(start='2019-01-01',     # 날짜 범위 시작
8                        end=None,               # 날짜 범위 끝
9                        periods=6,              # 생성할 Timestamp 개수
10                       freq='MS',              # 시간 간격(MS: 월의 시작일)
11                       tz='Asia/Seoul')        # 시간대(timezone)
12 print(ts_ms)
```

4개 옵션 중에 세 개만 구체적으로 지정. 4개 모두 지정하면 에러

〈실행 결과〉 코드 1~12라인을 부분 실행

```
DatetimeIndex(['2019-01-01 00:00:00+09:00', '2019-02-01 00:00:00+09:00',
               '2019-03-01 00:00:00+09:00', '2019-04-01 00:00:00+09:00',
               '2019-05-01 00:00:00+09:00', '2019-06-01 00:00:00+09:00'],
              dtype='datetime64[ns, Asia/Seoul]', freq='MS')
```

▪ Timestamp 배열 만들기2

freq옵션을 M으로 설정해보자. 이 경우 **월의 마지막 Timestamp**들을 원소로 생성한다.

freq옵션을 3M으로 설정해보자. 이 경우 **3개월 간격의 월의 마지막 Timestamp**들을 원소로 생성한다.

[예제 5-17]

```
15  # 월 간격, 월의 마지막 날 기준
16  ts_me = pd.date_range('2019-01-01', periods=6,
17                        freq='M',                    # 시간 간격(M: 월의 마지막 날)
18                        tz='Asia/Seoul')
19  print(ts_me)
20  print('\n')
21
22  # 분기(3개월) 간격, 월의 마지막 날 기준
23  ts_3m = pd.date_range('2019-01-01', periods=6,
24                        freq='3M',
25                        tz='Asia/Seoul')
26  print(ts_3m)
```

〈실행 결과〉 코드 15~26라인을 부분 실행

```
DatetimeIndex(['2019-01-31 00:00:00+09:00', '2019-02-28 00:00:00+09:00',
               '2019-03-31 00:00:00+09:00', '2019-04-30 00:00:00+09:00',
               '2019-05-31 00:00:00+09:00', '2019-06-30 00:00:00+09:00'],
              dtype='datetime64[ns, Asia/Seoul]', freq='M')


DatetimeIndex(['2019-01-31 00:00:00+09:00', '2019-04-30 00:00:00+09:00',
               '2019-07-31 00:00:00+09:00', '2019-10-31 00:00:00+09:00',
               '2020-01-31 00:00:00+09:00', '2020-04-30 00:00:00+09:00'],
              dtype='datetime64[ns, Asia/Seoul]', freq='3M')
```

▪ Period 배열 만들기1

판다스 period_range( )함수를 이용하면 여러 개의 Period가 들어 있는 배열 형태의 시계열 데이터를 만들 수 있다.
예제에서, 생성할 Period들의 시작 옵션은 '2019-01-01'으로 설정하고, 끝 옵션은 None으로 설정하였다. period 옵션은 3으로 설정하여 Period를 3개 생성하도록 하였다. freq 옵션은 M으로 설정하였는데 이는 월을 의미한다 .
정리하면, 2019년 1월1일을 시작으로 한달 간격으로 하여, 3개의 각 월(기간)을 원소로 가지는 Period 배열을 생성한다는 의미이다.

[예제 5-18]

```
4  import pandas as pd
5
6  # Period 배열 만들기 - 1개월 길이
7  pr_m = pd.period_range(start='2019-01-01',      # 날짜 범위 시작
8                         end=None,                # 날짜 범위 끝
9                         periods=3,               # 생성할 Period 개수
10                        freq='M')                # 기간의 길이(M: 월)
11 print(pr_m)
```

〈실행 결과〉 코드 1~11라인을 부분 실행

```
PeriodIndex(['2019-01', '2019-02', '2019-03'], dtype='period[M]', freq='M')
```

▪ Period 배열 만들기2

freq옵션을 H로 설정해보자. 이 경우 1시간 간격으로 Period 원소들을 총 3개 생성한다.

freq옵션을 2H로 설정해보자. 이 경우 2시간 간격으로 Period 원소들을 총 3개 생성한다.

[예제 5-18]

```
14 # Period 배열 만들기 - 1시간 길이
15 pr_h = pd.period_range(start='2019-01-01',     # 날짜 범위의 시작
16                       end=None,                # 날짜 범위의 끝
17                       periods=3,               # 생성할 Period 개수
18                       freq='H')                # 기간의 길이 (H: 시간)
19 print(pr_h)
20 print('₩n')
21
22 # Period 배열 만들기 - 2시간 길이
23 pr_2h = pd.period_range(start='2019-01-01',    # 날짜 범위의 시작
24                       end=None,                # 날짜 범위의 끝
25                       periods=3,               # 생성할 Period 개수
26                       freq='2H')               # 기간의 길이 (H: 시간)
27 print(pr_2h)
```

〈실행 결과〉 코드 14~27라인을 부분 실행

```
PeriodIndex(['2019-01-01 00:00', '2019-01-01 01:00', '2019-01-01 02:00'],
dtype='period[H]', freq='H')


PeriodIndex(['2019-01-01 00:00', '2019-01-01 02:00', '2019-01-01 04:00'],
dtype='period[2H]', freq='2H')
```

왜 Timestamp 또는 Period를 만드는가?

주식, 환율 등 금융 데이터를 다루기 위해 개발된 판다스는 시계열(time series) 데이터를 다루는 여러 가지 유용한 기능을 제공한다. 특히 시계열 데이터를 데이터프레임의 행 인덱스로 사용하면, 시간으로 기록된 데이터를 분석하는 것이 매우 편리하다.

판다스의 시간 표시 방식 중에서 시계열 데이터 표현에 자주 이용되는 두 가지 유형을 알아보자. 특정한 시점을 기록하는 Timestamp와 두 시점 사이의 일정한 기간을 나타내는 Period가 있다.

(a) 타임스탬프(Timestamp)

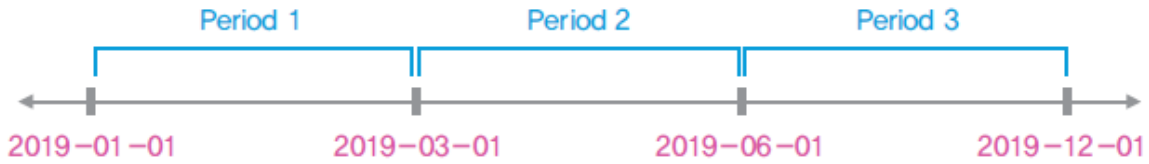

(b) 피리어드(Period)

[그림 5-2] 판다스 시간 표시

▪ '날짜 데이터' 분리1

시계열 데이터를 원소로 가지는 판다스 시리즈 객체의
dt.year, dt.month, dt.day 속성을 이용하여 연, 월, 일을 개별적으로 추출하자.

[예제 5-19]

```
4  import pandas as pd
5
6  # read_csv() 함수로 파일 읽어와서 df로 변환
7  df = pd.read_csv('stock-data.csv')
8
9  # 문자열인 날짜 데이터를 판다스 Timestamp로 변환
10 df['new_Date'] = pd.to_datetime(df['Date'])    # df에 새로운 열로 추가
11 print(df.head())
12 print('\n')
13
14 # dt 속성을 이용하여 new_Date 열의 연-월-일 정보를 년, 월, 일로 구분
15 df['Year'] = df['new_Date'].dt.year
16 df['Month'] = df['new_Date'].dt.month
17 df['Day'] = df['new_Date'].dt.day
18 print(df.head())
```

〈실행 결과〉 코드 1~18라인을 부분 실행

```
         Date  Close  Start   High    Low  Volume   new_Date
0  2018-07-02  10100  10850  10900  10000  137977 2018-07-02
1  2018-06-29  10700  10550  10900   9990  170253 2018-06-29
2  2018-06-28  10400  10900  10950  10150  155769 2018-06-28
3  2018-06-27  10900  10800  11050  10500  133548 2018-06-27
4  2018-06-26  10800  10900  11000  10700   63039 2018-06-26


         Date  Close  Start   High ...    new_Date  Year  Month  Day
0  2018-07-02  10100  10850  10900 ...  2018-07-02  2018      7    2
1  2018-06-29  10700  10550  10900 ...  2018-06-29  2018      6   29
2  2018-06-28  10400  10900  10950 ...  2018-06-28  2018      6   28
3  2018-06-27  10900  10800  11050 ...  2018-06-27  2018      6   27
4  2018-06-26  10800  10900  11000 ...  2018-06-26  2018      6   26
```

▪ '날짜 데이터' 분리2

시리즈 객체의 dt.to_period()메소드를 통해

Timestamp를 Period로 변환하여 년월일 표기 변경하고

추출한 날짜 정보를 데이터 프레임의 행인덱스로 지정하여 데이터를 관리할 수도 있다.

[예제 5-19]

```
21 #계속
22 # Timestamp를 Period로 변환하여 년월일 표기 변경하기
23 df['Date_yr'] = df['new_Date'].dt.to_period(freq='A')
24 df['Date_m'] = df['new_Date'].dt.to_period(freq='M')
25 print(df.head().to_markdown())
26 print('₩n')
27
28 # 원하는 열을 새로운 행 인덱스로 지정
29 df.set_index('Date_m', inplace=True)
30 print(df.head().to_markdown())
```

	Date	Close	Start	High	Low	Volume	new_Date	Year	Month	Day	Date_yr	Date_m
0	2018-07-02	10100	10850	10900	10000	137977	2018-07-02 00:00:00	2018	7	2	2018	2018-07
1	2018-06-29	10700	10550	10900	9990	170253	2018-06-29 00:00:00	2018	6	29	2018	2018-06
2	2018-06-28	10400	10900	10950	10150	155769	2018-06-28 00:00:00	2018	6	28	2018	2018-06
3	2018-06-27	10900	10800	11050	10500	133548	2018-06-27 00:00:00	2018	6	27	2018	2018-06
4	2018-06-26	10800	10900	11000	10700	63039	2018-06-26 00:00:00	2018	6	26	2018	2018-06

Date_m	Date	Close	Start	High	Low	Volume	new_Date	Year	Month	Day	Date_yr
2018-07	2018-07-02	10100	10850	10900	10000	137977	2018-07-02 00:00:00	2018	7	2	2018
2018-06	2018-06-29	10700	10550	10900	9990	170253	2018-06-29 00:00:00	2018	6	29	2018
2018-06	2018-06-28	10400	10900	10950	10150	155769	2018-06-28 00:00:00	2018	6	28	2018
2018-06	2018-06-27	10900	10800	11050	10500	133548	2018-06-27 00:00:00	2018	6	27	2018
2018-06	2018-06-26	10800	10900	11000	10700	63039	2018-06-26 00:00:00	2018	6	26	2018

▪ 날짜 인덱스의 활용1_시계열 데이터를 행인덱스로

Timestamp로 구성된 열을 행 인덱스로 지정하면 DatetimeIndex라는 고유 속성으로 변환된다. 마찬가지로 Period로 구성된 열을 행 인덱스로 지정하면 PeriodIndex라는 속성을 갖는다. 이와 같은 날짜 인덱스를 활용하면 시계열 데이터에 대한 인덱싱과 슬라이싱이 편리하다.

앞에서 사용한 주식 데이터를 불러와 to_datetime() 메소드를 이용하여 'Date' 열 데이터를 Timestamp로 변환하고 'new_Date' 열에 담는다. 그리고 set_index() 메소드로 'new_Date' 열을 데이터프레임의 행 인덱스로 지정한다. 행 인덱스 값들의 자료형은 datetime64[ns]이다.

[예제 5-20]

```
4  import pandas as pd
5
6  # read_csv() 함수로 파일 읽어와 df로 변환
7  df = pd.read_csv('stock-data.csv')
8
9  # 문자열인 날짜 데이터를 판다스 Timestamp로 변환
10 df['new_Date'] = pd.to_datetime(df['Date'])     # 새로운 열에 추가
11 df.set_index('new_Date', inplace=True)          # 행 인덱스로 지정
12
13 print(df.head())
14 print('\n')
15 print(df.index)
```

〈실행 결과〉 코드 1~15라인을 부분 실행

```
                 Date  Close  Start   High    Low  Volume
new_Date
2018-07-02  2018-07-02  10100  10850  10900  10000  137977
2018-06-29  2018-06-29  10700  10550  10900   9990  170253
2018-06-28  2018-06-28  10400  10900  10950  10150  155769
2018-06-27  2018-06-27  10900  10800  11050  10500  133548
2018-06-26  2018-06-26  10800  10900  11000  10700   63039


DatetimeIndex(['2018-07-02', '2018-06-29', '2018-06-28', '2018-06-27',
               '2018-06-26', '2018-06-25', '2018-06-22', '2018-06-21',
               '2018-06-20', '2018-06-19', '2018-06-18', '2018-06-15',
               '2018-06-14', '2018-06-12', '2018-06-11', '2018-06-08',
               '2018-06-07', '2018-06-05', '2018-06-04', '2018-06-01'],
              dtype='datetime64[ns]', name='new_Date', freq=None)
```

▪ 날짜 인덱스의 활용2

날짜 인덱스를 활용하는 장점은 연, 월, 일 기준으로 **내가 원하는 정보를 필터링하거나 슬라이싱** 하는 것.

loc 인덱서를 통해 원하는 정보에 접근할 수 있다.

[예제 5-20]

```
# 날짜 인덱스를 이용하여 데이터 선택하기
df_y = df.loc['2018']   #특정 연도 자료
print(df_y.head())
print('₩n')
df_ym = df.loc['2018-07']    #특정 연월 자료
print(df_ym)
print('₩n')
df_ymd = df.loc['2018-07-02']  #특정 연월일 자료
print(df_ymd)
print('₩n')
df_ym_cols = df.loc['2018-07', 'Start':'High']    # 연월 자료 + 열 슬라이싱
print(df_ym_cols)
print('₩n')
df_ymd_range = df.loc['2018-06-20':'2018-06-25']    # 연월일 자료 슬라이싱
print(df_ymd_range)
print('₩n')
df_ymd_list = df.loc[['2018-06-20','2018-06-25']]    # 연월일 자료 필터링
print(df_ymd_list)
print('₩n')
```

```
                Date  Close  Start   High    Low  Volume
new_Date
2018-07-02  2018-07-02  10100  10850  10900  10000  137977
2018-06-29  2018-06-29  10700  10550  10900   9990  170253
2018-06-28  2018-06-28  10400  10900  10950  10150  155769
2018-06-27  2018-06-27  10900  10800  11050  10500  133548
2018-06-26  2018-06-26  10800  10900  11000  10700   63039


                Date  Close  Start   High    Low  Volume
new_Date
2018-07-02  2018-07-02  10100  10850  10900  10000  137977


Date      2018-07-02
Close          10100
Start          10850
High           10900
Low            10000
Volume        137977
Name: 2018-07-02 00:00:00, dtype: object


            Start   High
new_Date
2018-07-02  10850  10900


                Date  Close  Start   High    Low  Volume
new_Date
2018-06-25  2018-06-25  11150  11400  11450  11000   55519
2018-06-22  2018-06-22  11300  11250  11450  10750  134805
2018-06-21  2018-06-21  11200  11350  11750  11200  133002
2018-06-20  2018-06-20  11550  11200  11600  10900  308596


                Date  Close  Start   High    Low  Volume
new_Date
2018-06-20  2018-06-20  11550  11200  11600  10900  308596
2018-06-25  2018-06-25  11150  11400  11450  11000   55519
```